Bicing Barcelona: Anàlisi de la disponibilitat, patrons d'ús i predicció de l'estat de les estacions

Vanessa Plaza · Itinerari d'Anàlisi de Dades · Cibernàrium / Barcelona Activa

2026

Resum

Aquest estudi analitza la disponibilitat del servei Bicing de Barcelona a partir de 291 milions de mesuraments recollits entre gerer 2020 i setembre 2025 en les 548 estacions de la xarxa. L'objectiu és quantificar la gravetat del problema de les estacions buides (sense bicicletes) i plenes (sense anclatges lliures), identificar-ne els patrons temporals i geogràfics, i avaluar la viabilitat de models predictius per anticipar aquestes situacions. La metodologia combina anàlisi exploratòria de dades amb DuckDB i Python, clustering K-Means per tipificar el comportament de les estacions, i avaluació de models predictius (Historical Average, Seasonal Naive 7d i Random Forest). Els resultats mostren que entre un 15% i un 25% de les franges de 30 minuts presenten problemes de disponibilitat, amb pics al matí laborable (8–10 h) i a la tarda (17–19 h). El clustering identifica 5 perfils diferenciats d'ús, des d'estacions perifèriques de baix ús fins a estacions centrals d'alta ocupació. El model Random Forest assoleix una balanced accuracy del 83%, superant amb escreix els baselines (Historical Average: 45%, Seasonal Naive: 53%). Es conclou que el problema és significatiu, periòdic i predictible, la qual cosa obre la porta a sistemes de redistribució proactiva de bicicletes basats en prediccions en temps real.

1. Introducció

El Bicing és el sistema de bicicletes compartides de Barcelona, gestionat per l'Ajuntament, amb 548 estacions distribuides per tota la ciutat. Des de la seva creació el 2007, el servei ha experimentat un creixement sostingut, especialment després de la pandèmia de la COVID-19, superant 1,1 milions de viatges mensuals de mitjana el 2024 (Ajuntament de Barcelona, 2025).

Tot i l'èxit del servei, un problema recurrent afecta la qualitat de l'experiència dels usuaris: les estacions que es queden completament **buides** (sense cap bicicleta disponible) o completament **plenes** (sense cap anclatge lliure per tornar una bicicleta). Aquesta situació genera frustració, pèrdua de temps i desincentiva l'ús del transport sostenible (Froehlich et al., 2009; Fishman et al., 2013).

L'objectiu d'aquest estudi és triple: (1) quantificar la magnitud i freqüència del problema de disponibilitat; (2) identificar els patrons temporals, geogràfics i tipològics que l'expliquen; i (3) demostrar que és possible predir l'estat de les estacions amb prou precisió per habilitar una redistribució proactiva de bicicletes.

2. Metodologia

Dades. El conjunt de dades prové del portal Open Data BCN de l'Ajuntament de Barcelona i conté 291 milions de mesuraments de disponibilitat de les 548 estacions Bicing, amb una freqüència d'aproximadament 5 minuts, entre gener de 2020 i setembre de 2025. Cada mesurament inclou la quantitat de bicicletes i anclatges disponibles, el timestamp i l'estat operatiu de l'estació. Les dades s'han enriquit amb informació geogràfica (coordenades, districte) i temporal (hora local de Barcelona amb zona Europe/Madrid, dia de la setmana, estació de l'any).

Preparació i emmagatzematge. Les dades s'han processat amb DuckDB, organitzant-les en sis capes: origen, neteja (eliminació de duplicats, conversió de tipus, filtratge d'estacions no operatives), mesuraments enriquits, agregacions de viatges, indicadors per clustering i avaluació de baselines. Els viatges s'estimen a partir de les caigudes en el nombre de bicicletes disponibles (delta_bicis < 0). L'anàlisi de disponibilitat es basa en franges de 30 minuts, on cada franja es classifica com a *buida* (0 bicis en algun moment), *plena* (0 anclatges), o *normal*. El període 2020–2021 s'exclou de les agregacions per les distorsions de la pandèmia.

Clustering. Per tipificar les estacions, s'ha aplicat K-Means (k=5) sobre 28 features derivades: capacitat mitjana, perfils del Nivell d'Availabilitat de Bicicletes (NAB) per franja horària (laborables i festius), variabilitat del NAB i ratios de saturació. Les features es normalitzen amb StandardScaler i es visualitzen amb PCA (2 components). La selecció del nombre de clústers s'ha guiat pel mètode del colze (inèrcia) i el coeficient de

Silhouette, avaluats per a k entre 2 i 12. S'ha escollit k=5 per l'equilibri entre compacitat dels grups i interpretabilitat dels perfils resultants.

Predicció. S'avaluen tres models per predir l'estat (buida/plena/normal) de cada franja de 30 minuts: (a) Historical Average (HA), que prediu la classe modal històrica per combinació d'estació, tipus de dia i franja; (b) Seasonal Naive 7 dies (SN7), que utilitza l'estat observat 7 dies abans; i (c) Random Forest, entrenat amb features temporals, geogràfiques i d'estat actual. El període d'entrenament és 2022–2024 i el de test és gener–setembre de 2025. Es reporten precision, recall, F1-score per classe i balanced accuracy.

3. Resultats

3.1. Magnitud del problema

L'anàlisi de les franges de 30 minuts entre 2022 i 2025 mostra que el problema de disponibilitat és significatiu i persistent. La Figura 1 i la Taula 1 presenten l'evolució dels percentatges de franges amb problemes.

Figura 1. *Evolució mensual del percentatge de franges de 30 min amb problemes de disponibilitat.*

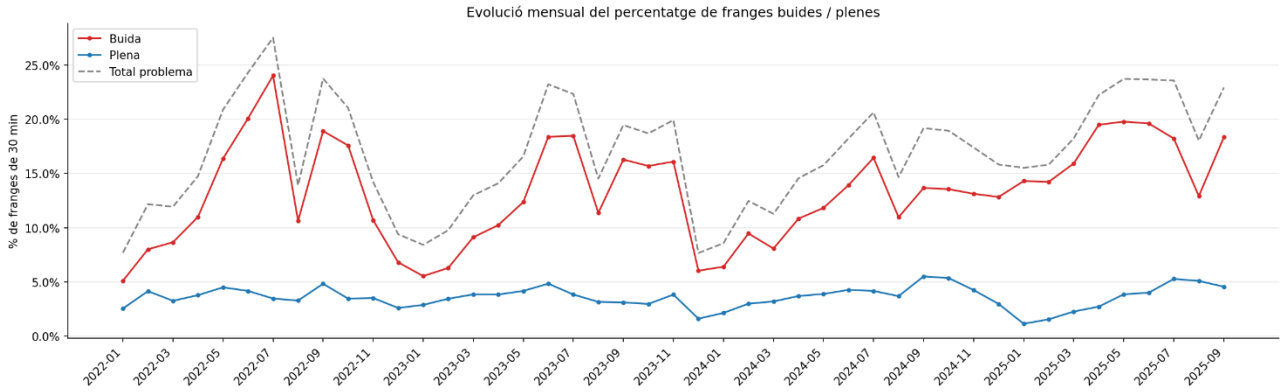

Taula 1. *Evolució anual del percentatge de franges de 30 min amb problemes de disponibilitat.*

Any	% Buida	% Plena	% Problema	% Sense mesures
2022	13,19	3,61	16,83	8,28
2023	12,21	3,45	15,69	15,01
2024	11,78	3,84	15,65	8,17
2025*	16,98	3,42	20,46	4,99

** Gener–setembre 2025. Font: Elaboració pròpia a partir d'Open Data BCN.*

Les estacions buides representen el problema dominant (12–17% de les franges), mentre que les plenes se situen al voltant del 3,5%. El 2025 mostra un increment notable al 17% de franges buides.

3.2. Patrons temporals

Els patrons horaris mostren dos pics d'estacions buides: al matí entre les 8 h i les 10 h (fins al 17,8%) i a la tarda entre les 17 h i les 19 h (fins al 19,2%), coincidint amb els desplacements de commuting. Per dia de la setmana, els dimarts a dijous concentren més problemes (~18,2%) que els caps de setmana (~15,3%). Estacionalment, l'estiu presenta el màxim (16,4% buides) i l'hivern el mínim (8,7%).

3.3. Patrons geogràfics i clustering

El districte de Sarrià-Sant Gervasi concentra les estacions més problemàtiques, amb estacions que superen el 50% del temps buides. Ciutat Vella mostra el problema invers, amb estacions que arriben al 23% del temps plenes. El clustering K-Means identifica 5 perfils diferenciats (Taula 2).

Taula 2. *Tipologia d'estacions identificada per K-Means (k=5).*

Cl.	Nom	N	% Buida	% Plena	NAB global
C0	Perifèric Baix Ús	132	20,6	0,4	0,22
C1	Central Alta Ocupació	42	3,9	13,7	0,59
C2	Origen Commuter Matí	162	12,3	2,4	0,37
C3	Ús Mixt Equilibrat	122	2,3	3,7	0,49
C4	Residencial Entrada Tarda	59	15,6	5,4	0,36

Font: Elaboració pròpia. NAB = Nivell d'Availabilitat de Bicicletes: proporció de bicicletes disponibles respecte a la capacitat de l'estació (0 = cap bicicleta disponible, 1 = totes les posicions ocupades per bicicletes)..

Figura 2. *Mapa de clústers*

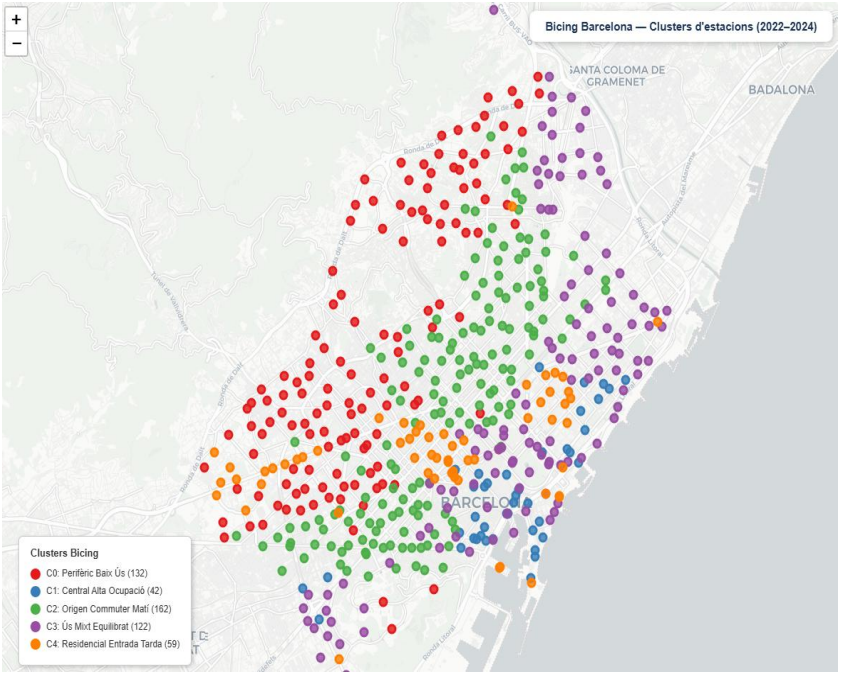

El clúster C0 (Perifèric Baix Ús, 132 estacions) presenta el ratio més alt de franges buides (20,6%), principalment en zones altes de Sarrià-Sant Gervasi. El C1 (Central Alta Ocupació, 42 estacions) mostra el problema invers, amb un 13,7% de franges plenes, concentrat a Ciutat Vella. El C3 (Ús Mixt Equilibrat, 122 estacions) és el perfil més estable, amb percentatges de problemes inferiors al 5%.

De les 548 estacions de la xarxa, 31 han estat excloses del clustering per presentar dades insuficients (>50% de franges sense mesuraments vàlids), resultant en 517 estacions analitzades.

3.4. Predicció de l'estat de les estacions

La Taula 3 compara les mètriques dels tres models avaluats sobre el període de test (gener–setembre 2025).

Taula 3. *Mètriques de predicció per model i classe (període de test: 2025).*

Model	Classe	Prec. %	Recall %	F1 %	Bal. Acc. %	Macro F1 %
Historical Avg.	Buida	49,5	28,3	36,0		
	Normal	83,3	92,0	87,4	45,4	47,5
	Plena	24,3	15,8	19,1		
Seasonal Naive 7d	Buida	46,2	45,5	45,9		
	Normal	85,7	85,2	85,5	52,5	52,8
	Plena	27,5	26,7	27,1		
Random Forest	Buida	53,1	87,8	66,2		
	Normal	96,1	74,9	84,2	83,2	64,6
	Plena	29,1	86,9	43,6		

Font: Elaboració pròpia. HA i SN7 calculats amb DuckDB; RF amb scikit-learn.

El model Historical Average mostra un biaix clar cap a la classe majoritària (*normal*), amb un recall molt baix tant per a les franges *buides* (28,3%) com per a les *plenes* (15,8%), fet que el fa poc útil per detectar situacions problemàtiques. El Seasonal Naive 7d millora lleugerament el comportament en classes minoritàries (recall del 45,5% per a *buida* i del 26,7% per a *plena*), però encara deixa escapar més de la meitat dels casos crítics. El Random Forest, en canvi, assoleix una balanced accuracy del 83%, amb un recall molt elevat per a les

franges *buides* (87,8%) i *plenes* (86,9%) i uns F1 clarament superiors als baselines en totes les classes, demostrant que és viable predir l'estat de les estacions amb alta fiabilitat operativa.

4. Discussió

Els resultats confirmen que el problema de disponibilitat del Bicing és estructural, no anecdòtic. Un 15–20% de les franges de 30 minuts presenten situacions en què l'usuari no pot agafar o tornar una bicicleta. Aquests percentatges són coherents amb la literatura sobre bike-sharing, que documenta problemes similars en sistemes com Vélib' (París), Citi Bike (Nova York) i Divvy (Chicago) (O'Brien et al., 2014; Fishman et al., 2013).

La identificació de 5 tipologies d'estacions mitjançant clustering aporta una eina directament accionable per als gestors del servei. El clúster C0 (Perifèric Baix Ús) i el C2 (Origen Commuter Matí) requereixen estratègies de reposició matinera, mentre que el C1 (Central Alta Ocupació) necessita alliberar anclatges a les hores punta. Aquesta segmentació permet dissenyar rutes de redistribució diferenciades per tipologia d'estació.

El Random Forest amb un 83% de balanced accuracy demostra que els patrons de demanda són altament regulars i predictibles. Les variables més importants són l'estat actual de l'estació (bicis i anclatges disponibles), l'hora del dia i l'historial recent de problemes. Aquesta predicció permetria als equips de redistribució actuar de forma preventiva, desplaçant bicicletes abans que les estacions arribin a situacions crítiques.

Limitacions. L'estimació de viatges es basa en la caiguda de bicicletes disponibles, però les reposicions de manteniment també generen variacions que no es poden distingir dels viatges reals. A més, les dades no inclouen informació sobre la demanda insatisfeta (usuaris que van a una estació buida i marxen sense bicicleta), de manera que el problema real podria ser encara més greu del que indiquen les xifres.

5. Conclusió

Aquest estudi demostra que el problema de disponibilitat del Bicing de Barcelona és significatiu (15–20% de les franges afectades), segueix patrons temporals i geogràfics clars i és altament predictible amb tècniques de machine learning. El clustering de les estacions ofereix una base per dissenyar estratègies de redistribució diferenciades, i el model Random Forest (83% balanced accuracy) demostra la viabilitat d'un sistema d'alerta temprana per anticipar situacions crítiques.

Com a propera línia de treball, es recomana integrar el model predictiu en un sistema de temps real que generi ordres de redistribució optimitzades, combinant les prediccions amb dades de posició dels vehicles de logística del servei.

Referències

Ajuntament de Barcelona. (2025). Bicing: Dades obertes de disponibilitat d'estacions. Open Data BCN. https://opendata-ajuntament.barcelona.cat/

Fishman, E., Washington, S., & Haworth, N. (2013). Bike share: A synthesis of the literature. Transport Reviews, 33(2), 148–165. https://doi.org/10.1080/01441647.2013.775612

Froehlich, J., Neumann, J., & Oliver, N. (2009). Sensing and predicting the pulse of the city through shared bicycling. Proceedings of the 21st International Joint Conference on Artificial Intelligence (IJCAI), 1420–1426.

O'Brien, O., Cheshire, J., & Batty, M. (2014). Mining bicycle sharing data for generating insights into sustainable transport systems. Journal of Transport Geography, 34, 262–273. https://doi.org/10.1016/j.jtrangeo.2013.06.007

Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

Raasveldt, M., & Mühleisen, H. (2019). DuckDB: An embeddable analytical database. Proceedings of the 2019 International Conference on Management of Data (SIGMOD), 1981–1984. https://doi.org/10.1145/3299869.3320212