Bicing Barcelona: Análisis de la disponibilidad, patrones de uso y predicción del estado de las estaciones

Vanessa Plaza · Itinerario de Análisis de Datos · Cibernàrium / Barcelona Activa

2026

Resumen

Este estudio analiza la disponibilidad del servicio Bicing de Barcelona a partir de 291 millones de mediciones recogidas entre enero de 2020 y septiembre de 2025 en las 548 estaciones de la red. El objetivo es cuantificar la gravedad del problema de las estaciones vacías (sin bicicletas) y llenas (sin anclajes libres), identificar sus patrones temporales y geográficos, y evaluar la viabilidad de modelos predictivos para anticipar estas situaciones. La metodología combina análisis exploratorio de datos con DuckDB y Python, clustering K-Means para tipificar el comportamiento de las estaciones, y evaluación de modelos predictivos (Historical Average, Seasonal Naive 7d y Random Forest). Los resultados muestran que entre un 15% y un 25% de las franjas de 30 minutos presentan problemas de disponibilidad, con picos por la mañana en días laborables (8–10 h) y por la tarde (17–19 h). El clustering identifica 5 perfiles diferenciados de uso, desde estaciones periféricas de bajo uso hasta estaciones centrales de alta ocupación. El modelo Random Forest alcanza una balanced accuracy del 83%, superando con creces los baselines (Historical Average: 45%, Seasonal Naive: 53%). Se concluye que el problema es significativo, periódico y predecible, lo que abre la puerta a sistemas de redistribución proactiva de bicicletas basados en predicciones en tiempo real.

1. Introducción

El Bicing es el sistema de bicicletas compartidas de Barcelona, gestionado por el Ayuntamiento, con 548 estaciones distribuidas por toda la ciudad. Desde su creación en 2007, el servicio ha experimentado un crecimiento sostenido, especialmente tras la pandemia de la COVID-19, superando 1,1 millones de viajes mensuales de media en 2024 (Ajuntament de Barcelona, 2025).

A pesar del éxito del servicio, un problema recurrente afecta la calidad de la experiencia de los usuarios: las estaciones que se quedan completamente **vacías** (sin ninguna bicicleta disponible) o completamente **llenas** (sin ningún anclaje libre para devolver una bicicleta). Esta situación genera frustración, pérdida de tiempo y desincentiva el uso del transporte sostenible (Froehlich et al., 2009; Fishman et al., 2013).

El objetivo de este estudio es triple: (1) cuantificar la magnitud y frecuencia del problema de disponibilidad; (2) identificar los patrones temporales, geográficos y tipológicos que lo explican; y (3) demostrar que es posible predecir el estado de las estaciones con suficiente precisión para habilitar una redistribución proactiva de bicicletas.

2. Metodología

Datos. El conjunto de datos proviene del portal Open Data BCN del Ayuntamiento de Barcelona y contiene 291 millones de mediciones de disponibilidad de las 548 estaciones Bicing, con una frecuencia de aproximadamente 5 minutos, entre enero de 2020 y septiembre de 2025. Cada medición incluye la cantidad de bicicletas y anclajes disponibles, el timestamp y el estado operativo de la estación. Los datos se han enriquecido con información geográfica (coordenadas, distrito) y temporal (hora local de Barcelona con zona Europe/Madrid, día de la semana, estación del año).

Preparación y almacenamiento. Los datos se han procesado con DuckDB, organizándolos en seis capas: origen, limpieza (eliminación de duplicados, conversión de tipos, filtrado de estaciones no operativas), mediciones enriquecidas, agregaciones de viajes, indicadores para clustering y evaluación de baselines. Los viajes se estiman a partir de las caídas en el número de bicicletas disponibles (delta_bicis < 0). El análisis de disponibilidad se basa en franjas de 30 minutos, donde cada franja se clasifica como *vacía* (0 bicis en algún momento), *llena* (0 anclatges), o *normal*. El período 2020–2021 se excluye de las agregaciones por las distorsiones de la pandemia.

Clustering. Para tipificar las estaciones, se ha aplicado K-Means (k=5) sobre 28 variables derivadas: capacidad media, perfiles del Nivel de Disponibilidad de Bicicletas (NAB) por franja horaria (laborables y

festivos), variabilidad del NAB y ratios de saturación. Las variables se normalizan con StandardScaler y se visualizan con PCA (2 componentes). La selección del número de clústers se ha guiado por el método del codo (inercia) y el coeficiente de Silhouette, evaluados para k entre 2 y 12. Se ha elegido k=5 por el equilibrio entre compacidad de los grupos e interpretabilidad de los perfiles resultantes.

Predicción. Se evalúan tres modelos para predecir el estado (vacía/llena/normal) de cada franja de 30 minutos: (a) Historical Average (HA), que predice la clase modal histórica por combinación de estación, tipo de día y franja; (b) Seasonal Naive 7 días (SN7), que utiliza el estado observado 7 días antes; y (c) Random Forest, entrenado con variables temporales, geográficas y de estado actual. El período de entrenamiento es 2022–2024 y el de test es enero–septiembre de 2025. Se reportan precision, recall, F1-score por clase y balanced accuracy.

3. Resultados

3.1. Magnitud del problema

El análisis de las franjas de 30 minutos entre 2022 y 2025 muestra que el problema de disponibilidad es significativo y persistente. La Figura 1 y la Tabla 1 presentan la evolución de los porcentajes de franjas con problemas.

Figura 1. *Evolución mensual del porcentaje de franjas de 30 min con problemas de disponibilidad.*

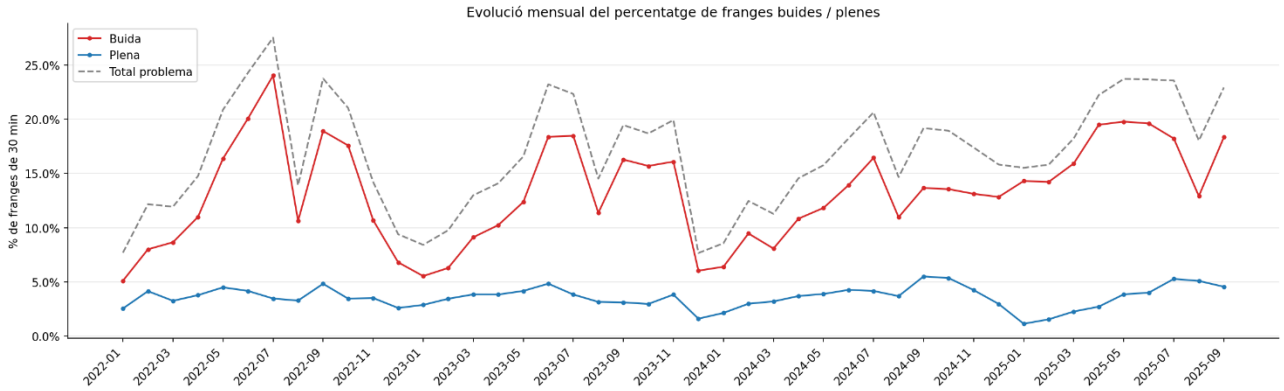

Tabla 1. *Evolución anual del porcentaje de franjas de 30 min con problemas de disponibilidad.*

Año	% Vacía	% Llena	% Problema	% Sin mediciones
2022	13,19	3,61	16,83	8,28
2023	12,21	3,45	15,69	15,01
2024	11,78	3,84	15,65	8,17
2025*	16,98	3,42	20,46	4,99

** Enero–septiembre 2025. Fuente: Elaboración propia a partir de Open Data BCN.*

Las estaciones vacías representan el problema dominante (12–17% de las franjas), mientras que las llenas se sitúan alrededor del 3,5%. El 2025 muestra un incremento notable al 17% de franjas vacías.

3.2. Patrones temporales

Los patrones horarios muestran dos picos de estaciones vacías: por la mañana entre las 8 h y las 10 h (hasta el 17,8%) y por la tarde entre las 17 h y las 19 h (hasta el 19,2%), coincidiendo con los desplazamientos de commuting. Por día de la semana, los martes a jueves concentran más problemas (~18,2%) que los fines de semana (~15,3%). Estacionalmente, el verano presenta el máximo (16,4% vacías) y el invierno el mínimo (8,7%).

3.3. Patrones geográficos y clustering

El distrito de Sarrià-Sant Gervasi concentra las estaciones más problemáticas, con estaciones que superan el 50% del tiempo vacías. Ciutat Vella muestra el problema inverso, con estaciones que llegan al 23% del tiempo llenas. El clustering K-Means identifica 5 perfiles diferenciados (Tabla 2).

Tabla 2. *Tipología de estaciones identificada por K-Means (k=5).*

Cl.	Nombre	N	% Vacía	% Llena	NAB global
C0	Periférico Bajo Uso	132	20,6	0,4	0,22
C1	Central Alta Ocupación	42	3,9	13,7	0,59
C2	Origen Commuter Mañana	162	12,3	2,4	0,37
C3	Uso Mixto Equilibrado	122	2,3	3,7	0,49
C4	Residencial Entrada Tarde	59	15,6	5,4	0,36

Fuente: Elaboración propia. NAB = Nivel de Disponibilidad de Bicicletas: proporción de bicicletas disponibles respecto a la capacidad de la estación (0 = ninguna bicicleta disponible, 1 = todas las posiciones ocupadas por bicicletas).

Figura 2. *Mapa de clústeres*

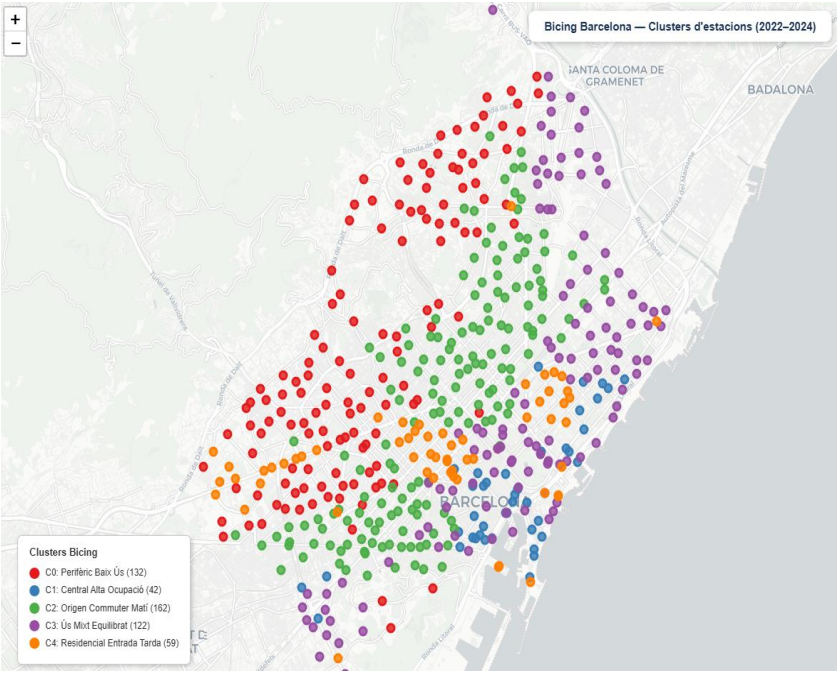

El clúster C0 (Periférico Bajo Uso, 132 estaciones) presenta el ratio más alto de franjas vacías (20,6%), principalmente en zonas altas de Sarrià-Sant Gervasi. El C1 (Central Alta Ocupación, 42 estaciones) muestra el problema inverso, con un 13,7% de franjas llenas, concentrado en Ciutat Vella. El C3 (Uso Mixto Equilibrado, 122 estaciones) es el perfil más estable, con porcentajes de problemas inferiores al 5%.

De las 548 estaciones de la red, 31 han sido excluidas del clustering por presentar datos insuficientes (>50% de franjas sin mediciones válidas), resultando en 517 estaciones analizadas.

3.4. Predicción del estado de las estaciones

La Tabla 3 compara las métricas de los tres modelos evaluados sobre el período de test (enero–septiembre 2025).

Tabla 3. *Métricas de predicción por modelo y clase (período de test: 2025).*

Modelo	Clase	Prec. %	Recall %	F1 %	Bal. Acc. %	Macro F1 %
Historical Avg.	Vacía	49,5	28,3	36,0		
	Normal	83,3	92,0	87,4	45,4	47,5
	Llena	24,3	15,8	19,1		
Seasonal Naive 7d	Vacía	46,2	45,5	45,9		
	Normal	85,7	85,2	85,5	52,5	52,8
	Llena	27,5	26,7	27,1		
Random Forest	Vacía	53,1	87,8	66,2		
	Normal	96,1	74,9	84,2	83,2	64,6
	Llena	29,1	86,9	43,6		

Fuente: Elaboración propia. HA y SN7 calculados con DuckDB; RF con scikit-learn.

El modelo Historical Average muestra un sesgo claro hacia la clase mayoritaria (*normal*), con un recall muy bajo tanto para las franjas *vacías* (28,3%) como para las *llenas* (15,8%), lo que lo hace poco útil para detectar situaciones problemáticas. El Seasonal Naive 7d mejora ligeramente el comportamiento en clases minoritarias (recall del 45,5% para *vacía* y del 26,7% para *llena*), pero todavía deja escapar más de la mitad

de los casos críticos. El Random Forest, en cambio, alcanza una balanced accuracy del 83%, con un recall muy elevado para las franjas *vacías* (87,8%) y *llenas* (86,9%) y unos F1 claramente superiores a los baselines en todas las clases, demostrando que es viable predecir el estado de las estaciones con alta fiabilidad operativa.

4. Discusión

Los resultados confirman que el problema de disponibilidad del Bicing es estructural, no anecdótico. Un 15–20% de las franjas de 30 minutos presentan situaciones en que el usuario no puede coger o devlver una bicicleta. Estos porcentajes son coherentes con la literatura sobre bike-sharing, que documenta problemas similares en sistemas como Vélib' (París), Citi Bike (Nueva York) y Divvy (Chicago) (O'Brien et al., 2014; Fishman et al., 2013).

La identificación de 5 tipologías de estaciones mediante clustering aporta una herramienta directamente accionable para los gestores del servicio. El clúster C0 (Periférico Bajo Uso) y el C2 (Origen Commuter Mañana) requieren estrategias de reposición matutina, mientras que el C1 (Central Alta Ocupación) necesita liberar anclajes en las horas punta. Esta segmentación permite diseñar rutas de redistribución diferenciadas por tipología de estación.

El Random Forest con un 83% de balanced accuracy demuestra que los patrones de demanda son altamente regulares y predecibles. Las variables más importantes son el estado actual de la estación (bicis y anclajes disponibles), la hora del día y el historial reciente de problemas. Esta predicción permitiría a los equipos de redistribución actuar de forma preventiva, desplazando bicicletas antes de que las estaciones lleguen a situaciones críticas.

Limitaciones. La estimación de viajes se basa en la caída de bicicletas disponibles, pero las reposiciones de mantenimiento también generan variaciones que no se pueden distinguir de los viajes reales. Además, los datos no incluyen información sobre la demanda insatisfecha (usuarios que van a una estación vacía y se marchan sin bicicleta), por lo que el problema real podría ser aún más grave de lo que indican las cifras.

5. Conclusión

Este estudio demuestra que el problema de disponibilidad del Bicing de Barcelona es significativo (15–20% de las franjas afectadas), sigue patrones temporales y geográficos claros y es altamente predecible con técnicas de machine learning. El clustering de las estaciones ofrece una base para diseñar estrategias de redistribución diferenciadas, y el modelo Random Forest (83% balanced accuracy) demuestra la viabilidad de un sistema de alerta temprana para anticipar situaciones críticas.

Como próxima línea de trabajo, se recomienda integrar el modelo predictivo en un sistema de tiempo real que genere órdenes de redistribución optimizadas, combinando las predicciones con datos de posición de los vehículos de logística del servicio.

Referencias

Ajuntament de Barcelona. (2025). Bicing: Datos abiertos de disponibilidad de estaciones. Open Data BCN. https://opendata-ajuntament.barcelona.cat/

Fishman, E., Washington, S., & Haworth, N. (2013). Bike share: A synthesis of the literature. Transport Reviews, 33(2), 148–165. https://doi.org/10.1080/01441647.2013.775612

Froehlich, J., Neumann, J., & Oliver, N. (2009). Sensing and predicting the pulse of the city through shared bicycling. Proceedings of the 21st International Joint Conference on Artificial Intelligence (IJCAI), 1420–1426. https://www.ijcai.org/Proceedings/09/Papers/238.pdf [acceso libre]

O'Brien, O., Cheshire, J., & Batty, M. (2014). Mining bicycle sharing data for generating insights into sustainable transport systems. Journal of Transport Geography, 34, 262–273. https://doi.org/10.1016/j.jtrangeo.2013.06.007

Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830. https://jmlr.org/papers/volume12/pedregosa11a/pedregosa11a.pdf [acceso libre]

Raasveldt, M., & Mühleisen, H. (2019). DuckDB: An embeddable analytical database. Proceedings of the 2019 International Conference on Management of Data (SIGMOD), 1981–1984. https://doi.org/10.1145/3299869.3320212